

# Hidden Markov Model

---

## Markov Model

---

$A_1 \rightarrow A_2 \rightarrow A_3 \cdots \rightarrow A_i \rightarrow A_{i+1} \cdots \rightarrow A_n \rightarrow$

M 个离散结点形成一条链

- 若每个结点有 K 个状态，则需要  $K-1 + (M-1)K(K-1)$  个参数， $O(M)$
- 如果是全连接，则需要  $K^M - 1$  个参数， $O(K^M)$

$A_1$  会有 K 个变化，比方当  $A_1=1$  时，需要给出  $A_2 = i$  这么多个参数,  $i$  为  $(0,k)$ ，所以是  $K(K-1)$  个参数

链状模型可以极大减少我们需要学习的参数的数目

若状态  $A_i$  确定，则  $A_{i+1}$  只与  $A_i$  有关，与  $A_1, \dots, A_{i-1}$  无关，伪随机过程

$$p(\theta^{t+1} \mid \theta^{(1)}, \theta^{(2)}, \dots, \theta^{(t)}) = p(\theta^{t+1} \mid \theta^{(t)})$$

例子：C 语言中的伪随机函数使用的是 Markov Model，实际上只要知道第  $i$  个随机数，就可以计算出第  $i+1$  个随机数

满足 Markov 模型的样本点  $s_1, s_2 \dots s_n$  与『独立同分布』只弱一点：样本间只有相邻元素有相关关系，并且，有些以『独立同分布』为条件的定理，是可以放松到 Markov Process 的。例如：大数定理。

## Hidden Markov Model

---

HMM 是关于时序的概率模型，描述由一个隐藏的 Markov Chain 随机生成的不可观测的状态最忌序列，再有各个状态生成一个观测二产生观测随机序列的过程。

HMM 随机生成的状态序列，称为状态序列；每个状态生成一个观测，由此产生的观测随机序列，称为观测序列。序列的每个位置可以看做是一个时刻

$$\begin{array}{ccccccc}
 z_1 & \rightarrow & z_2 & \rightarrow & \cdots & \rightarrow & z_{n-1} \rightarrow z_n \rightarrow z_{n+1} \rightarrow \\
 \downarrow & & \downarrow & & & & \downarrow & \downarrow & \downarrow \\
 x_1 & & x_2 & & & & x_{n-1} & x_n & x_{n+1}
 \end{array}$$

在  $z_1, z_2$  不可观察的前提下

- $x_1$  和  $z_2$  独立吗？不独立
- $x_1$  和  $x_2$  独立吗？不独立

## HMM 的确定

---

由出事概率分布  $\pi$ ，状态转移分布  $A$  以及观测概率分布  $B$  确定。

$$\lambda = (A, B, \pi)$$

假设我们的 HMM 模型如下

$$\begin{array}{ccccccc}
 z_1 & \rightarrow & z_2 & \rightarrow & \cdots & \rightarrow & z_{n-1} \rightarrow z_n \rightarrow z_{n+1} \rightarrow \\
 \downarrow & & \downarrow & & & & \downarrow & \downarrow & \downarrow \\
 x_1 & & x_2 & & & & x_{n-1} & x_n & x_{n+1}
 \end{array}$$

- $Q$  是所有可能的状态的集合
  - $N$  是可能的状态数目
  - $Q = \{q_1, q_2, \dots, q_N\}$
- $V$  是所有可能的观测的集合
  - $M$  是可能的观测数
  - $V = \{v_1, v_2, \dots, v_M\}$

$I$  是长度为  $T$  的状态序列， $O$  是对应的观测序列

$$\begin{aligned}
 I &= \{i_1, i_2, \dots, i_T\} \\
 O &= \{o_1, o_2, \dots, o_T\}
 \end{aligned}$$

**A** 是状态转移概率矩阵

$$\begin{aligned}
 A &= [a_{ij}]_{N \times N} \\
 a_{ij} &= P(i_{t+1} \mid i_t = q_i)
 \end{aligned}$$

$a_{ij}$  是在时刻  $t$  处于 状态  $q_i$  的条件下时刻  $t+1$  转移到概率  $q_j$  的概率

**B** 是观测概率矩阵

$$B = [b_{ik}]_{N \times M}$$
$$b_{ik} = P(o_t = v_k \mid i_t = q_i)$$

$b_{ik}$  是在时刻  $t$  处于状态  $q_i$  的条件下生成观测  $v_k$  的概率

$\pi$  是初始状态概率向量

$$\pi = (\pi_i)$$
$$\pi_i = P(i_1 = q_i)$$

$\pi_i$  是时刻  $t=1$  处于状态  $q_i$  的概率

## 两个基本性质

---

$$\begin{array}{ccccccc} z_1 & \rightarrow & z_2 & \rightarrow & \cdots & \rightarrow & z_{n-1} & \rightarrow & z_n & \rightarrow & z_{n+1} & \rightarrow \\ \downarrow & & \downarrow & & & & \downarrow & & \downarrow & & \downarrow & \\ x_1 & & x_2 & & & & x_{n-1} & & x_n & & x_{n+1} \end{array}$$

齐次假设

$$P(i_t \mid i_{t-1}, o_{t-1}, i_{t-2}, o_{t-2}, \dots, i_1, o_1) = P(i_t \mid i_{t-1})$$

这里  $i_t$  对应  $z_n$  输入的概率,  $o_{t-1}$  这些对应  $x_{n-1}$  的观测, 也就是说,  $z_n$  的状态实际上只由  $z_{n-1}$  决定

观测独立性假设

$$P(o_t \mid i_t, i_{t-1}, o_{t-1}, i_{t-2}, o_{t-2}, \dots, i_1, o_1) = P(o_t \mid i_t)$$

也就是说在时刻  $t$ , 得到观测  $o_t$  的概率只跟  $i_t$  有关 (通过查  $B$  矩阵即可)

## 举例

---

假设有 3 个盒子, 编号为 1 2 3, 每个盒子都装有红白两种颜色的小球

盒子号	1	2	3

红球	5	4	7
白球	5	6	3

按照下面的方法抽取小球，得到球颜色的观测序列：

- 按照  $\pi = (0.2, 0.4, 0.4)$  来选择一个盒子，抽取一个球后放回
- 按某条件概率选择新的盒子，重复上述过程
- 最终得到观测序列：红红白白红

## 各个参数

- 状态集合： $Q = \{\text{盒子1}, \text{盒子2}, \text{盒子3}\}$
- 观测集合： $V = \{\text{红}, \text{白}\}$
- 状态序列和观测序列的长度  $T=5$
- 初始概率分布  $\pi = (0.2, 0.4, 0.4)$
- 状态转移概率分布  $A$
- 观测概率分布  $B$  (一行是一个分布)

$$\pi = \begin{pmatrix} 0.2 \\ 0.4 \\ 0.4 \end{pmatrix} \quad A = \begin{pmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{pmatrix} \quad B = \begin{pmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{pmatrix}$$

## 三个基本问题

---

### 概率计算问题

给定模型  $\lambda = (A, B, \pi)$  和观测序列  $O = \{o_1, o_2, \dots, o_T\}$ ，计算模型  $\lambda$  下观测序列  $O$  出现的概率  $P(O | \lambda)$

### 学习问题

已知观测序列  $O = \{o_1, o_2, \dots, o_T\}$ ，估计模型  $\lambda = (A, B, \pi)$  的参数，使得在该模型下观测序列  $P(O | \lambda)$  最大

### 预测问题

即解码问题，已知模型  $\lambda = (A, B, \pi)$  和观测序列  $O = \{o_1, o_2, \dots, o_T\}$ ，求对给

定观测序列条件概率  $P(I|\lambda;O)$  最大的状态序列  $I$ 。

## 概率计算问题

### 直接计算法

按照概率公式，列举所有可能的长度为  $T$  的状态序列  $I = \{i_1, i_2, \dots, i_T\}$ ，求各个状态序列  $I$  与观测序列  $O = \{o_1, o_2, \dots, o_T\}$  的联合概率  $P(O, I | \lambda)$ ，然后对所有可能的状态求和，从而得到  $P(O | \lambda)$

状态序列  $I = \{i_1, i_2, \dots, i_T\}$  的概率是：

$$P(I | \lambda) = \pi_{i_1} a_{i_1 i_2} a_{i_2 i_3} \dots a_{i_{T-1} i_T}$$

对固定的状态序列  $I$ ，观测序列  $O$  的概率是

$$P(O | I, \lambda) = b_{i_1 o_1} b_{i_2 o_2} \dots b_{i_T o_T}$$

$O$  和  $I$  同时出现的联合概率

$$\begin{aligned} P(O, I | \lambda) &= P(O | I, \lambda) P(I | \lambda) \\ &= \pi_{i_1} b_{i_1 o_1} a_{i_1 i_2} b_{i_2 o_2} a_{i_2 i_3} \dots a_{i_{T-1} i_T} b_{i_T o_T} \end{aligned}$$

对所有可能的状态序列  $I$  求和，得到观测序列  $O$  的概率  $P(O | \lambda)$

$$\begin{aligned} P(O | \lambda) &= \sum_I P(O, I | \lambda) = \sum_I P(O | I, \lambda) P(I | \lambda) \\ &= \sum_{i_1, i_2, \dots, i_T} \pi_{i_1} b_{i_1 o_1} a_{i_1 i_2} b_{i_2 o_2} a_{i_2 i_3} \dots a_{i_{T-1} i_T} b_{i_T o_T} \end{aligned}$$

分析：加和符号中有  $2T$  个因子， $I$  的遍历个数为  $N^T$ ，时间复杂度为  $O(T N^T)$ ，复杂度过高

## 前向算法

定义：给定  $\lambda$ ，定义到时刻  $t$ ，部分观测序列为  $o_1, o_2, \dots, o_t$  且隐状态为  $q_i$  的概率为 **前向概率**，记作

$$\alpha_t(i) = P(o_1, o_2, \dots, o_t, i_t = q_i | \lambda)$$

可以递推计算前向概率  $\alpha_t(i)$  以及观测序列概率  $P(O \mid \lambda)$

初值:  $\alpha_1(i) = \pi_i b_{i o_1}$

递推, 对于  $t = 1, 2, \dots, T - 1$ , 这里的  $a_{ji}$  是矩阵 A 中从状态 j 转移到状态 i 的值

$$\alpha_{t+1}(i) = \left( \sum_{j=1}^N \alpha_t(j) a_{ji} \right) b_{i o_{t+1}}$$

最终

$$P(O \mid \lambda) = \sum_{i=1}^N \alpha_T(i)$$

前向概率算法的时间复杂度是  $O(TN^2)$

## 例子

还是用刚才的小球的例子, 计算观测向量  $O = \text{红白红}$  的出现概率, 其中

$$\pi = \begin{pmatrix} 0.2 \\ 0.4 \\ 0.4 \end{pmatrix} \quad A = \begin{pmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{pmatrix} \quad B = \begin{pmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{pmatrix}$$

计算初值,  $o_1$  表示红色,  $o_2$  表示白色

$$\alpha_1(\text{盒子1}) = \pi_1 b_{1 o_1} = 0.2 \times 0.5 = 0.1$$

$$\alpha_1(\text{盒子2}) = \pi_2 b_{2 o_1} = 0.4 \times 0.4 = 0.16$$

$$\alpha_1(\text{盒子3}) = \pi_3 b_{3 o_1} = 0.4 \times 0.7 = 0.28$$

递推

$$\begin{aligned} \alpha_2(i = 1) &= \left( \sum_{j=1}^N \alpha_1(j) a_{j1} \right) b_{1 o_2} \\ &= (0.1 \times 0.5 + 0.16 \times 0.3 + 0.28 \times 0.2) \times 0.5 \\ &= 0.077 \end{aligned}$$

$$\alpha_2(2) = 0.1104$$

$$\alpha_2(3) = 0.606$$

$$\alpha_3(1) = 0.04187$$

$$\alpha_3(2) = 0.03551$$

$$\alpha_3(3) = 0.05284$$

最终

$$\begin{aligned} P(O \mid \lambda) &= \sum_{i=1}^3 \alpha_3(i) \\ &= 0.04187 + 0.03551 + 0.05284 \\ &= 0.13022 \end{aligned}$$

## 后向算法

---

定义：给定  $\lambda$ ，定义到时刻  $t$  隐状态为  $q_i$  的前提下，从  $t+1$  到  $T$  的部分观测序列概率为  $o_{t+1}, o_{t+2}, \dots, o_T$  的概率为**后向概率**，记作

$$\beta_t(i) = P(o_{t+1}, o_{t+2}, \dots, o_T \mid i_t = q_i, \lambda)$$

可以递推计算前向概率  $\beta_t(i)$  以及观测序列概率  $P(O \mid \lambda)$

初值： $\beta_T(i) = 1$

递推，对于  $t = T - 1, T - 2, \dots, 1$ ，这里的  $a_{ij}$  是矩阵  $A$  中从状态  $i$  转移到状态  $j$  的值

$$\beta_t(i) = \left( \sum_{j=1}^N a_{ij} b_{j o_{t+1}} \beta_{t+1}(j) \right)$$

最终

$$P(O \mid \lambda) = \sum_{i=1}^N \pi_i b_{i o_1} \beta_1(i)$$

为了计算在时刻  $t$  隐状态为  $q_i$  条件下，时刻  $t+1$  之后观测序列为

$o_{t+1}, o_{t+2}, \dots, o_T$  的后向概率  $\beta_t(i)$ ，只需要考虑在时刻  $t+1$  所有可能的  $N$  个状态

$q_j$  的转移概率( $a_{ij}$  项), 以及在此状态下的观测  $o_{t+1}$  的观测概率( $b_{jo_{t+1}}$  项), 然后考虑状态  $q_j$  之后的观测序列的后向概率  $\beta_{t+1}(j)$

## 前向后向概率的关系

---

根据定义, 可得

$$P(i_t = q_i, O \mid \lambda) = \alpha_t(i)\beta_t(i)$$

$$P(O \mid \lambda) = \sum_{i=1}^N \alpha_t(i)\beta_t(i)$$

## 单个状态的概率

---

给定模型  $\lambda$  和观测  $O$ , 求在时刻  $t$  处于状态  $q_i$  的概率

$$\gamma_t(i) = P(i_t = q_i \mid O, \lambda)$$

根据前向后向概率的定义

$$P(i_t = q_i, O \mid \lambda) = \alpha_t(i)\beta_t(i)$$

$$\gamma_t(i) = P(i_t = q_i \mid O, \lambda) = \frac{P(i_t = q_i, O \mid \lambda)}{P(O \mid \lambda)}$$

$$\gamma_t(i) = \frac{\alpha_t(i)\beta_t(i)}{P(O \mid \lambda)} = \frac{\alpha_t(i)\beta_t(i)}{\sum_{i=1}^N \alpha_t(i)\beta_t(i)}$$

## 两个状态的联合概率

---

给定模型  $\lambda$  和观测  $O$ , 求在时刻  $t$  处于状态  $q_i$  并且时刻  $t+1$  处于时刻  $q_j$  的概率

$$\xi_t(i, j) = P(i_t = q_i, i_{t+1} = q_j \mid O, \lambda)$$

根据前向后向概率的定义



$$\begin{aligned}
 \xi_t(i, j) &= P(i_t = q_i, i_{t+1} = q_j \mid O, \lambda) \\
 &= \frac{P(i_t = q_i, i_{t+1} = q_j, O \mid \lambda)}{P(O \mid \lambda)} \\
 &= \frac{P(i_t = q_i, i_{t+1} = q_j, O \mid \lambda)}{\sum_{i=1}^N \sum_{j=1}^N P(i_t = q_i, i_{t+1} = q_j, O \mid \lambda)} \\
 P(i_t = q_i, i_{t+1} = q_j, O \mid \lambda) &= \alpha_t(i) a_{ij} b_{j_{O_{t+1}}} \beta_{t+1}(j)
 \end{aligned}$$

## 学习算法

- 若训练数据包括观测序列和状态序列，则 HMM 的学习是监督学习 -> MLE
- 若训练数据只有观测序列，则 HMM 的学习需要使用 EM 算法，是非监督学习

## 监督学习方法

假设已给定训练数据包含 S 个长度相同的观测序列和对应的状态序列

$\{(O_1, I_1), (O_2, I_2), \dots, (O_s, I_s)\}$ ，那么，可以直接给出 HMM 的参数估计，直接用频率去估计概率

### 转移概率 $a_{ij}$ 的估计

设样本中时刻 t 处于状态 i，时刻 t+1 转移到状态 j 的频数是  $A_{ij}$ ，则

$$\hat{a}_{ij} = \frac{A_{ij}}{\sum_{j=1}^N A_{ij}}$$

### 观测概率 $b_{ik}$ 的估计

设样本中状态 i 并且观测为 k 的频数为  $B_{ik}$ ，则

$$\hat{b}_{ij} = \frac{B_{ik}}{\sum_{k=1}^N B_{ik}}$$

### 初始状态的估计

$\pi_i$  的估计为 S 个样本中初始状态为  $q_i$  的概率

# 非监督学习 Baum-Welch 算法

所有观测数据写成  $O = (o_1, o_2, \dots, o_T)$ , 所有隐数据写成  $I = (i_1, i_2, \dots, i_T)$ , 完全数据是  $(O, I) = (o_1, o_2, \dots, o_T, i_1, i_2, \dots, i_T)$ , 完全数据的对数似然函数是  $\ln P(O, I \mid \lambda)$

假设  $\bar{\lambda}$  是 HMM 参数当前的估计值,  $\lambda$  为待求的参数,  $P(O, I \mid \bar{\lambda})$  可以看作是对数似然函数在当前条件下取值的概率, 用来求期望

$$Q(\bar{\lambda}, \lambda) = \sum_I \ln P(O, I \mid \lambda) P(O, I \mid \bar{\lambda})$$

## EM 过程

根据

$$\begin{aligned} P(O, I \mid \lambda) &= P(O \mid I, \lambda) P(I \mid \lambda) \\ &= \pi_{i_1} b_{i_1 o_1} a_{i_1 i_2} b_{i_2 o_2} a_{i_2 i_3} \cdots a_{i_{T-1} i_T} b_{i_T o_T} \end{aligned}$$

函数可写成 (把  $\pi, a, b$  分开)

$$\begin{aligned} Q(\bar{\lambda}, \lambda) &= \sum_I \ln P(O, I \mid \lambda) P(O, I \mid \bar{\lambda}) \\ &= \sum_I \ln \pi_{i_1} P(O, I \mid \bar{\lambda}) + \sum_I \left( \sum_{t=1}^{T-1} \ln a_{i_t i_{t+1}} \right) P(O, I \mid \bar{\lambda}) + \sum_I \left( \sum_{t=1}^T \ln b_{i_t o_t} \right) P(O, I \mid \bar{\lambda}) \end{aligned}$$

极大化 Q, 求得参数  $A, B, \pi$

由于这三个参数分别位于三个项中, 可分别极大化

## 初始概率

$$\sum_I \ln \pi_{i_1} P(O, I \mid \bar{\lambda}) = \sum_{i=1}^N \ln \pi_{i_1} P(O, i_1 = i \mid \bar{\lambda})$$

注意到  $\pi_i$  满足加和为 1, 利用拉格朗日乘子法, 得到

$$\sum_{i=1}^N \ln \pi_{i_1} P(O, i_1 = i | \bar{\lambda}) + \gamma \left( \sum_{i=1}^N \pi_i - 1 \right)$$

对上式相对于  $\pi_i$  求偏导，得到

$$P(O, i_1 = i | \bar{\lambda}) + \gamma \pi_i = 0;$$

对 i 求和，得到

$$\gamma = -P(O | \bar{\lambda})$$

从而得到初始状态概率

$$\pi_i = \frac{P(O, i_1 = i | \bar{\lambda})}{P(O | \bar{\lambda})}$$

## 转移概率和观测概率

第二项可写成

$$\sum_I \left( \sum_{t=1}^{T-1} \ln a_{i_t i_{t+1}} \right) P(O, I | \bar{\lambda}) = \sum_{i=1}^N \sum_{j=1}^N \sum_{t=1}^{T-1} \ln a_{ij} P(O, i_t = i, i_{t+1} = j | \bar{\lambda})$$

仍然使用拉格朗日乘子法，得到

$$a_{ij} = \frac{\sum_{t=1}^{T-1} P(O, i_t = i, i_{t+1} = j | \bar{\lambda})}{\sum_{t=1}^{T-1} P(O, i_t = i | \bar{\lambda})} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)}$$

同理，对于观测概率，得到

$$b_{ik} = \frac{\sum_{t=1}^T P(O, i_t = i | \bar{\lambda}) I(o_t = v_k)}{\sum_{t=1}^T P(O, i_t = i | \bar{\lambda})} \frac{\sum_{t=1, o_t=v_k}^T \gamma_t(i)}{\sum_{t=1}^T \gamma_t(i)}$$

## 预测算法

---

### 预测的近似算法

在每个时刻  $t$  选择在该时刻最有可能出现的状态  $i_t^*$ ，从而得到一个隐状态序列  $I^* = \{i_1^*, i_2^*, \dots, i_T^*\}$ ，将它作为预测的结果

给定模型和观测序列，时刻  $t$  处于状态  $q_i$  的概率为

$$\gamma_t(i) = \frac{\alpha_t(i)\beta_t(i)}{P(O|\lambda)} = \frac{\alpha_t(i)\beta_t(i)}{\sum_{i=1}^N \alpha_t(i)\beta_t(i)}$$

选择概率最大的  $i$  作为最有可能的状态（会出现此状态在实际中可能不会发生的情况）

## Viterbi 算法

用动态规划解 HMM 预测问题，用 DP 求概率最大的路径，一条路径对应一个状态序列。

定义变量  $\delta_t(i)$ ：在时刻  $t$  状态为  $i$  的所有路径中，概率的最大值

定义

$$\delta_t(i) = \max_{i_1, i_2, \dots, i_{t-1}} P(i_t = i, i_{t-1}, \dots, i_1, o_t, \dots, o_1 | \lambda)$$

递推

$$\begin{aligned} \delta_1(i) &= \pi_i b_{io_1} \\ \delta_{t+1}(i) &= \max_{i_1, i_2, \dots, i_t} P(i_{t+1} = i, i_t, \dots, i_1, o_{t+1}, \dots, o_1 | \lambda) \\ &= \max_{1 \leq j \leq N} (\delta_t(j) a_{ji}) b_{io_{t+1}} \end{aligned}$$

终止

$$P^* = \max_{1 \leq i \leq N} \delta_T(i)$$

## 例子

还是用刚才的小球的例子，观测向量  $O$ =红白红，试求最优状态序列

$$\pi = \begin{pmatrix} 0.2 \\ 0.4 \\ 0.4 \end{pmatrix} \quad A = \begin{pmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{pmatrix} \quad B = \begin{pmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{pmatrix}$$

初始化，在  $t=1$  时，对于每一个状态  $i$ ，求状态为  $i$  观测到  $o_1 = red$  (矩阵  $B$  的第一列) 的概率，记为  $\delta_1(i)$

$$\delta_1(i) = \pi_i b_{i o_1} = \pi_i b_{i, red}$$

求得

$$\delta_1(1) = 0.2 \times 0.5 = 0.1$$

$$\delta_1(2) = 0.4 \times 0.4 = 0.16$$

$$\delta_1(3) = 0.4 \times 0.8 = 0.28$$

在  $t=2$  时，对每个状态  $i$ ，求在  $t=1$  时状态为  $j$  观测为红并且在  $t=2$  时状态为  $i$  观测为白的路径的最大概率，记为  $\delta_2(i)$ ，这里  $o_2 = white$  则：

$$\delta_{t+1}(i) = \max_{1 \leq j \leq 3} (\delta_1(j) a_{ji}) b_{i o_2} = \max_{1 \leq j \leq 3} (\delta_1(j) a_{j1}) b_{i, white}$$

求得

$$\begin{aligned} \delta_2(1) &= \max_{1 \leq j \leq 3} (\delta_1(j) a_{j1}) b_{1, white} \\ &= \max\{0.10 \times 0.5, 0.16 \times 0.3, 0.28 \times 0.2\} \times 0.5 = 0.028 \end{aligned}$$

同理可得

$$\delta_2(2) = 0.0504$$

$$\delta_2(3) = 0.042$$

继续可以求得

$$\delta_3(1) = 0.00756$$

$$\delta_3(2) = 0.01008$$

$$\delta_3(3) = 0.0147$$

所以最大是  $\delta_3(3) = 0.0147$ ，根据每一步最大，得到的序列是(3,3,3)